


Informe predictivo demanda de energía

1. Variables candidatas para el modelo multivariado y justificación de la elección

El primer paso es seleccionar variables candidatas para el modelo multivariado. El objetivo es encontrar relaciones entre las variables predictoras y la variable objetivo que será la demanda de energía.

La base de un modelo multivariado es la distribución normal multivariada y se fundamentan en la relación lineal entre variables, la cual se cuantifica mediante la matriz de covarianza que nos dice cómo se relacionan las variables entre sí. La propiedad de esta distribución normal multivariada es que se define por su vector de medias y matriz de covarianzas.

El primer paso será calcular la matriz de correlación de todas las variables y seleccionaremos aquellas tres variables que muestren la correlación más fuerte con nuestra variable objetivo. La calcularemos de forma numérica, así como gráfica que será la imagen mostrada a continuación:



Este es el gráfico de la matriz de correlación en el que podemos ver que las tres variables candidatas para predecir la demanda de energía son la temperatura media, el consumo histórico y el desempleo.

- Temperatura media (temperatura_media, correlación: -0,72). Es la candidata más fuerte de todas con una correlación negativa alta, es decir, a medida que aumenta la temperatura media, la demanda de energía disminuye. Esto podría ser lógico en zonas donde el uso de la calefacción en meses fríos es el principal motivo del consumo energético.
- Consumo histórico (consumo_historico, correlación: 0.55). Es la segunda candidata, aunque tiene una correlación positiva moderada. Lo que explicaría sería que si el consumo en el pasado aumentaba, también lo hace el del presente.
- Desempleo (correlación: -0.19). Es una correlación débil, pero la tercera más fuerte. Lo que explicaría es que a medida que el desempleo aumenta, se reduciría la demanda de energía. Por ejemplo, esas personas desempleadas intentarían evitar consumir energía excesiva que les suponga un elevado precio a final de mes, lo cual podría ser lógico teniendo en cuenta que la correlación no es fuerte.

Las variables del gasto del consumidor y de la inflación son muy pequeñas, con coeficientes cercanos a 0, por lo que las descartamos inicialmente.

Esta matriz de correlación es una versión normalizada de la matriz de covarianza de una distribución normal multivariada y lo que hace es medir la fuerza de la relación lineal entre dos variables. Al seleccionar las variables con mayor correlación absoluta, estamos identificando, a priori, las variables que pueden explicar la varianza de la variable objetivo dentro del modelo lineal.

Por tanto, usaremos la correlación para seleccionar las variables que mejor describen la matriz de la covarianza de una distribución multivariada. Esto nos permitiría construir un modelo de regresión lineal, que es una de las posibilidades, el cual optimizaremos con la máxima verosimilitud.

No obstante, debemos tener en cuenta que la correlación no siempre implica causalidad, es decir, hemos observado asociaciones estadísticas entre las variables, pero no podemos afirmar que el descenso de dichas

variables implique el descenso de nuestra variable objetivo, ya que podría existir una variable exógena que cause el descenso de ambas a la vez en el caso de una relación lineal positiva.

2. Relación de estas variables con el contexto empresarial

No sólo debemos fijarnos en la estadística, sino también en cómo se relacionan las variables predictoras y la variable objetivo con el contexto empresarial, en este caso, una empresa de servicios energéticos.

- Demanda de la energía (variable objetivo). Esta es la variable de respuesta y el indicador de rendimiento más crítico para la empresa, por ello es la variable que intentamos predecir con nuestro modelo. Estimar la demanda de la energía implica poder anticiparse y tomar una serie de decisiones estratégicas clave en la empresa cómo gestionar la red para evitar cortes de suministros, ajustar la producción a la demanda, planificar el mantenimiento o comprar energía en otros mercados.
- Temperatura media (variable candidata). La interpretación empresarial que deducimos de su relación lineal negativa con la demanda de energía es que el principal consumo en la región estudiada es la calefacción. Por ello, cuando disminuye la temperatura, aumenta la demanda de energía, ya que muchas más personas pondrán la calefacción evitando el frío. Las previsiones meteorológicas podrán permitir anticipar posibles picos de demanda de energía.
- Consumo histórico (variable candidata). Esta variable se puede interpretar como que las personas tienen un patrón de consumo estable en cuanto al consumo de energía.
- Desempleo (variable candidata). El desempleo es una variable macroeconómica y, aunque su correlación es más débil, tiene su explicación tanto por la industria como por los hábitos de consumo. Por un lado, las personas desempleadas intentarían evitar consumir energía excesiva que les suponga un elevado precio a final de mes. Por otro, una mayor tasa de desempleo suele estar ligada a una menor actividad industrial y comercial, por lo que se reduce la demanda energética.

Por tanto, estas tres variables se pueden interpretar desde el contexto empresarial y no sólo de forma estadística.

3. Modelos propuestos

Dado que la variable objetivo es continua, no podremos usar modelos de clasificación como la Regresión Logística. Los modelos a implementar serán los siguientes:

- Regresión Lineal Múltiple: es la implementación directa de la Regresión Lineal Multivariada y es un modelo ideal para describir la relación entre una variable dependiente (objetivo) y un conjunto de variables explicativas. Su objetivo es encontrar los coeficientes que minimizan el error cuadrático que, en el supuesto de errores normales, coincide con el estimador de Máxima Verosimilitud. Este es el modelo propuesto:

```
[1] "Resumen del Modelo 1"

Call:
lm(formula = demanda_energia ~ temperatura_media + consumo_historico +
    desempleo, data = datos)

Residuals:
    Min       1Q   Median       3Q      Max
-738.67 -192.39   28.06  176.61  606.98

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  6687.33959   161.83695   41.321 < 2e-16 ***
temperatura_media -99.80772    3.95385  -25.243 < 2e-16 ***
consumo_historico   0.50333    0.02438   20.649 < 2e-16 ***
desempleo        -79.03611    9.15668   -8.632 2.08e-15 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 258.8 on 196 degrees of freedom
Multiple R-squared:  0.8552, Adjusted R-squared:  0.853
F-statistic: 385.8 on 3 and 196 DF, p-value: < 2.2e-16
```

El intercepto (intercept) es el valor cuando todas las variables son 0 y en este modelo es de 6687,34, es decir, la demanda base de la energía. Este modelo es muy interpretativo y podemos explicar la correlación y peso de los coeficientes. La temperatura media (-99,81) y el desempleo (-79,03) influyen de forma negativa en la demanda de energía, es decir, cuando estas aumentan, la demanda de energía disminuye dado el signo negativo de los coeficientes. El consumo histórico (0,5) tiene correlación positiva, pero mucho más pequeña que las anteriores variables y lo que muestra es una inercia de consumo.

El p-valor en todas las variables es muy pequeño y por debajo de 0,05, lo cual implica que las variables son estadísticamente significativas, es decir, todas ellas influyen en la demanda.

Nuestro modelo tiene un R-squared de aproximadamente 0.85, lo que significa que explica el 85,3% de la variabilidad de la demanda de energía. Por tanto, con tan solo tres variables somos capaces de explicar la mayor parte del comportamiento de la demanda.

- Regresión Lineal con interacciones: este modelo extiende el anterior, aunque es más complejo puesto que asume que el efecto de una variable pueda depender del valor de otra. Es decir, puede ser que una variable explicativa no tenga un efecto constante sobre la variable objetivo, sino que pueda ser mucho mayor un día debido a otra de las variables explicativas. Por ejemplo, una bajada de 1 grado podría aumentar la demanda mucho más en una zona con alto consumo histórico (zona industrial) que en una con bajo consumo (zona residencial). Por tanto, en este modelo añadiremos la interacción entre la temperatura media y el consumo histórico. Este es el modelo propuesto:

[1] "Resumen del Modelo 2"

```
call:
lm(formula = demanda_energia ~ temperatura_media + consumo_historico +
    desempleo + temperatura_media:consumo_historico, data = datos)

Residuals:
    Min       1Q   Median       3Q      Max
-741.94 -175.85   25.06  175.81  588.75

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    7.198e+03  5.658e+02  12.721  < 2e-16 ***
temperatura_media -1.244e+02  2.640e+01  -4.711  4.68e-06 ***
consumo_historico  4.039e-01  1.084e-01   3.725  0.000256 ***
desempleo       -7.988e+01  9.203e+00  -8.680  1.57e-15 ***
temperatura_media:consumo_historico  4.877e-03  5.181e-03   0.941  0.347664
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 258.9 on 195 degrees of freedom
Multiple R-squared:  0.8558,    Adjusted R-squared:  0.8529
F-statistic: 289.4 on 4 and 195 DF,  p-value: < 2.2e-16
```

El intercepto (intercept) en este modelo es de 7198, es decir, la demanda base de la energía. La temperatura media (-124,4) y el desempleo (-79,8) también influyen de forma negativa en la demanda de energía. El consumo histórico (0,4) y la interacción entre la temperatura media y el consumo histórico (0,0048) tienen correlación positiva, pero mucho más pequeñas que las anteriores variables, especialmente la interacción que es casi insignificante.

El p-valor en todas las variables compartidas con el modelo uno es muy pequeño y por debajo de 0,05, lo cual implica que las variables son estadísticamente significativas, es decir, todas ellas influyen en la demanda. No obstante, la nueva variable introducida, la interacción, tiene un p-valor de 0,34, mucho mayor que el umbral de 0,05, lo que significa que no es estadísticamente significativa, por lo que añadir esta complejidad no ha mejorado el modelo.

Nuestro modelo tiene un R-squared de aproximadamente 0.85, lo que significa que explica el 85,29% de la variabilidad de la demanda de energía, inferior al anterior pese a que es más complejo.

4. Justificación de cuál es el mejor modelo

Una vez ejecutados ambos modelos es necesario confirmar nuestra interpretación previa de que el modelo 1 es mejor que el modelo 2. Para ello vamos a utilizar los criterios de selección de modelos Akaike Information Criterion (AIC) y Bayesian Information Criterion (BIC).

Estos modelos nos proporcionan una métrica relativa y se elige aquel con menor valor de AIC o BIC. La función de ambos es encontrar el ajustes de los datos (verosimilitud) con la penalización por complejidad (número de parámetros), evitando así la posibilidad de que nuestro modelo caiga en sobreajuste.

AIC favorece a los modelos con buen ajuste, pero penaliza el número de parámetros, mientras que BIC tiende a seleccionar modelos más simples en grandes muestras porque penaliza también el tamaño de la muestra.

Modelo <chr>	AIC <dbl>	BIC <dbl>
Modelo 1 (RLM Simple)	2796.021	2812.512
Modelo 2 (Con Interacción)	2797.114	2816.904

Estos son los resultados AIC y BIC de nuestro modelo y podemos observar que el mejor modelo en este caso es el modelo 1, puesto que tiene el AIC y el BIC más bajo y, tal y como hemos comentado arriba, el modelo superior es aquel que presenta los valores AIC y BIC más bajos puesto que representa equilibrio entre precisión y simplicidad.

Esto ocurre porque en el modelo 2 incluimos un parámetro extra, la interacción entre la temperatura media y el consumo histórico, y la mejora en el ajuste que este parámetro puede proporcionar no es suficiente para justificar su complejidad.

5. ¿Es necesario regularizar el modelo seleccionado?

La técnica de regularización se utiliza para resolver dos problemas en los modelos de regresión:

- overfitting (sobreajuste): ocurre cuando el modelo es demasiado complejo al tener muchas variables irrelevantes y el modelo se ajusta demasiado al ruido de los datos de entrenamiento.
- multicolinealidad: ocurre cuando las variables predictoras están fuertemente correlacionadas entre sí.

En primer lugar, no tenemos muchas variables irrelevantes, ya que realizamos una selección de tres variables en la primera parte basada en la correlación. Así, descartamos dos variables que eran irrelevantes y sólo aportarían ruido al modelo (inflación y gasto del consumidor). Nuestro modelo 1 sólo usa tres predictores.

En cuanto a la multicolinealidad, volvemos a observar la matriz de correlación para estudiar la correlación entre las variables predictoras seleccionadas:

- Correlación temperatura_media, consumo_historico: -0.03
- Correlación temperatura_media, desempleo: 0.07
- Correlación desempleo, consumo_historico: 0.17

Podemos observar que todos los valores de correlación entre nuestras variables predictoras son muy bajos, cercanos a 0, es decir, cada variable aporta información única, limpia y no redundante al modelo. Por tanto, no existe un problema de multicolinealidad en nuestro modelo.

La conclusión final es que nuestro modelo no necesita regularización, sino que es suficiente y estable para el problema que tratamos de resolver.